

## Mini-Challenge 1: Hyperparameter und Model Tuning

### Ziel

Implementiere, trainiere und validiere ein Neuronales Netzwerk Modell für einen Klassifikationstask mit geeignetem Dataset (z. B. Bewegungsklassifikation mit dem [Activity Recognition Dataset](#)). Ihr könnt ein geeignetes Datenset vorschlagen - es sollte nicht zu gross sein (um viele verschiedene Modell- und Parametervarianten evaluieren zu können, aber auch nicht zu klein, so dass noch vernünftig ML gemacht werden kann. Der Fokus der Mini-Challenge soll auf die Evaluation der Modellvarianten und Settings der Hyperparameter gelegt werden. Ausserdem sollten nicht zu ausgeklügelte komplexe Modell-Architekturen untersucht werden. Ein MLP für die Klassifikation allenfalls mit ein paar CNN-Layern für Feature-Extraktion sollte ausreichen. Falls Bild-Daten verwendet werden, könnt Ihr auch *Transfer-Learning* verwenden, um Features aus den Bildern herauszuholen, um diese dann mit MLPs zu untersuchen.

### Arbeitsschritte

#### Schritt 1: Daten Kennenlernen

1. Implementiere Funktionalität, um den Datensatz zu laden.
2. Mache Dich mit dem Datensatz vertraut, indem Du eine explorative Analyse der Features durchführst: z.B. Vergleich der Klassen pro Feature, Balanciertheit der Klassen.
3. Führe ein geeignetes Preprocessing durch: Normalisierung der Daten.

#### Schritt 2: Aufbau Modellierung

4. Lege fest, wie (mit welchen Metriken) Du die Modelle evaluieren möchtest. Berücksichtige auch den Fehler in der Schätzung dieser Metriken.
5. Implementiere Basisfunktionalität, um Modelle zu trainieren und gegeneinander zu evaluieren. Wie sollen die Gewichte initialisiert werden?

#### Schritt 3: Training mit SGD, ohne REG, ohne BN

6. Untersuche verschiedene Modelle unterschiedlicher Komplexität, welche geeignet sein könnten, um das Klassifikationsproblem zu lösen. Verwende Stochastic Gradient Descent - ohne Beschleunigung, ohne Regularisierung (REG) und ohne Batchnorm (BN).
  - a. Für jedes Modell mit gegebener Anzahl Layer und Units pro Layer führe ein sorgfältiges Hyper-Parameter-Tuning durch (Lernrate, Batch-Grösse). Achte stets darauf, dass das Training stabil läuft. Merke Dir bei jedem Training, den Loss, die Performance Metrik(en) inkl. Schätzfehler, die verwendete Anzahl Epochen, Lernrate und Batch-Grösse.
  - b. Variiere die Anzahl Layer und Anzahl Units pro Layer, um eine möglichst gute Performance zu erreichen. Falls auch CNNs (ohne Transfer-Learning) verwendet werden variiere auch Anzahl Filter, Kernel-Grösse, Stride, Padding.
  - c. Fasse die Ergebnisse zusammen in einem geeigneten Plot, bilde eine Synthese und folgere, welche Modell-Komplexität Dir am sinnvollsten erscheint.

#### **Schritt 4: Nutzen der Regularisierung**

7. Ziehe nun verschiedene Regularisierungsmethoden bei den MLP Layern in Betracht:
  - a. L1/L2 Weight Penalty
  - b. DropoutAnsonsten folge denselben Schritten wie in 6.
8. Evaluiere den Nutzen der Regularisierung, auch unter Berücksichtigung verschiedener Regularisierungsstärken. Beschreibe auch kurz, was allgemein das Ziel von Regularisierungsmethoden ist (Regularisierung im Allgemeinen, sowie auch Idee der einzelnen Methoden). Inwiefern wird dieses Ziel im gegebenen Fall erreicht?

#### **Schritt 5: Nutzen von Batchnorm BN (ohne REG, mit SGD)**

9. Evaluiere, ob Batchnorm etwas bringt. Beschreibe kurz, was die Idee von BN ist, wozu es helfen soll.

#### **Schritt 6: Nutzen von Adam (ohne BN, ohne / mit REG)**

10. Evaluiere, ob Du mit Adam bessere Resultate erzielen kannst.
11. Versuche den erreichten / nicht erreichten Nutzen zu interpretieren.

Alle oben genannten Schritte sollen in einem *gut strukturierten* und *gut dokumentierten* Jupyter-Notebook durchgeführt werden. Dieses soll schliesslich auch abgegeben werden und dem Fachexperten erlauben, die Schritte nachzuvollziehen (allenfalls auch das Training erneut laufen zu lassen).

### **Beurteilung**

Beurteilt wird auf Basis des abgegebenen Notebooks:

- Vollständige und korrekte Umsetzung der oben beschriebenen Aufgabestellung (Implementierung im gewählten DL-Framework, Untersuchung der verschiedenen Varianten).
- Gut gewählte und gut kommentierten Plots und Tabellen.
- Schlüssige Beschreibung und Interpretation der Ergebnisse.